

Asignatura propuesta

Testing de sistemas de IA generativa basados en LLMs

Programa técnico de estudio para construir la metodología del TFG

Carácter: Asignatura teórico-práctica orientada a comprender el funcionamiento técnico de los modelos de lenguaje de gran tamaño y a diseñar metodologías de evaluación para sistemas conversacionales basados en IA generativa.

Objetivo general de la asignatura: Comprender los fundamentos técnicos, históricos y metodológicos necesarios para diseñar una metodología de testing aplicable a chatbots educativos basados en modelos de lenguaje de gran tamaño.

Resultados de aprendizaje

1. Explicar la evolución del procesamiento del lenguaje natural hasta los LLMs actuales.
2. Comprender el papel de la arquitectura Transformer en el desarrollo de los modelos modernos.
3. Distinguir entre modelo de lenguaje, chatbot conversacional, sistema RAG y agente basado en LLMs.
4. Identificar los principales riesgos técnicos de los LLMs: alucinaciones, sesgos, falta de robustez, problemas de seguridad y sobreconfianza.
5. Comparar el testing tradicional de software con el testing de sistemas generativos.
6. Diseñar dimensiones de evaluación para respuestas generadas por IA.
7. Construir rúbricas y casos de prueba basados en prompts.
8. Aplicar una metodología de evaluación a un chatbot educativo basado en LLMs.

Programa de la asignatura

Módulo 1. Evolución histórica del procesamiento del lenguaje natural

Tema 1. Orígenes de la inteligencia artificial y del NLP

Contenidos teóricos

- Primeras ideas sobre inteligencia artificial.
- Alan Turing y el test de Turing.
- IA simbólica y sistemas basados en reglas.
- Primeros sistemas conversacionales.
- ELIZA, desarrollado por Joseph Weizenbaum en 1966.
- Limitaciones de los sistemas basados en reglas.
- Paso progresivo hacia modelos estadísticos.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
1950	Test de Turing	Alan Turing
1956	Conferencia de Dartmouth	John McCarthy, Marvin Minsky, Claude Shannon, Nathaniel Rochester
1966	ELIZA	Joseph Weizenbaum, MIT

Por qué importa para el TFG: Permite explicar que los chatbots no nacen con ChatGPT. Existe una evolución desde sistemas rígidos basados en reglas hasta sistemas generativos capaces de producir lenguaje abierto.

Tema 2. NLP estadístico y aprendizaje automático clásico

Contenidos teóricos

- Procesamiento del lenguaje natural como disciplina.
- Modelos estadísticos del lenguaje.
- N-gramas.
- Modelos ocultos de Markov.
- Clasificación textual.
- Bag of Words.
- TF-IDF.
- Ingeniería manual de características.
- Limitaciones de los modelos clásicos ante contexto, ambigüedad y significado.

Contenidos prácticos

- Analizar cómo representaría un texto un modelo Bag of Words.
- Comparar una representación TF-IDF con una representación semántica moderna.
- Identificar por qué un modelo clásico falla ante una pregunta ambigua.

Por qué importa para el TFG: Ayuda a justificar que los LLMs representan un salto respecto a técnicas anteriores, especialmente por su capacidad de generar respuestas abiertas y contextuales.

Módulo 2. Deep learning aplicado al lenguaje

Tema 3. Representaciones vectoriales del lenguaje

Contenidos teóricos

- Del texto simbólico a los vectores.
- Concepto de embedding.
- Word embeddings.
- Word2Vec.
- GloVe.
- Similitud semántica.
- Representaciones distribuidas.
- Diferencia entre embeddings estáticos y contextuales.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
2013	Word2Vec	Tomas Mikolov, Google
2014	GloVe	Stanford NLP

Contenidos prácticos

- Representar palabras como vectores.
- Comparar similitud semántica entre términos.
- Explicar por qué "rey - hombre + mujer $\approx$ reina" fue un ejemplo famoso de embeddings.

Por qué importa para el TFG: Los embeddings explican cómo los modelos pasan de texto a representaciones numéricas y son clave para entender LLMs, búsqueda semántica y sistemas RAG.

Tema 4. Redes neuronales secuenciales para lenguaje

Contenidos teóricos

- Redes neuronales recurrentes.
- RNN.
- LSTM.
- GRU.
- Procesamiento secuencial.
- Dependencias largas.
- Problemas de memoria y gradientes.
- Limitaciones frente a textos largos.

Contenidos prácticos

- Comparar cómo una RNN y un Transformer procesan una frase.
- Identificar el problema de dependencias largas en un ejemplo educativo.

Por qué importa para el TFG: Sirve para entender por qué el Transformer fue un avance decisivo y por qué permitió escalar los modelos de lenguaje modernos.

Módulo 3. Arquitectura Transformer y nacimiento de los LLMs modernos

Tema 5. La arquitectura Transformer

Contenidos teóricos

- Paper "Attention Is All You Need".
- Problema que resuelve el Transformer.
- Self-attention.
- Multi-head attention.
- Positional encoding.
- Encoder.
- Decoder.
- Paralelización del entrenamiento.
- Ventajas frente a RNN y LSTM.
- Costes y limitaciones.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
2017	Publicación de "Attention Is All You Need"	Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Łukasz Kaiser, Illia Polosukhin; Google

Contenidos prácticos

- Dibujar el flujo básico de un Transformer.
- Explicar con un ejemplo qué partes de una frase atiende el modelo.
- Comparar encoder-only, decoder-only y encoder-decoder.

Por qué importa para el TFG: Es el hito técnico central. La mayoría de los LLMs actuales derivan de esta arquitectura.

Tema 6. Familias de modelos basadas en Transformer

Contenidos teóricos

- Modelos encoder-only.
- BERT.
- Modelos decoder-only.
- GPT.
- Modelos encoder-decoder.
- T5.
- Diferencias entre comprensión y generación.
- Modelos autoregresivos.
- Modelos enmascarados.
- Preentrenamiento y fine-tuning.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
2018	BERT	Google - modelo bidireccional encoder-only
2018	GPT-1	OpenAI - Generative Pre-trained Transformer
2019	GPT-2	OpenAI - escalado generativo y debate sobre publicación
2020	GPT-3	OpenAI - 175.000 millones de parámetros
2020	T5	Google - enfoque text-to-text

Contenidos prácticos

- Clasificar modelos según su arquitectura.
- Explicar qué tipo de tareas encajan mejor con BERT y cuáles con GPT.
- Comparar generación autoregresiva y masked language modeling.

Por qué importa para el TFG: Tu trabajo evaluará chatbots generativos, por lo que necesitas entender especialmente los modelos decoder-only tipo GPT.

Módulo 4. Grandes modelos de lenguaje

Tema 7. Preentrenamiento, escalado y capacidades emergentes

Contenidos teóricos

- Preentrenamiento autosupervisado.
- Corpus masivos.
- Predicción del siguiente token.
- Escalado de parámetros.
- Scaling laws.
- Coste computacional.
- GPUs y TPUs.
- Capacidades emergentes.

- Few-shot learning.
- Zero-shot learning.
- In-context learning.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
2020	GPT-3 y few-shot learning	OpenAI
2022	Chinchilla scaling laws	DeepMind
2023	Expansión masiva de LLMs abiertos y comerciales	OpenAI, Google, Meta, Anthropic, Mistral AI

Contenidos prácticos

- Diseñar un prompt zero-shot y otro few-shot.
- Analizar cómo cambia la respuesta al añadir ejemplos.
- Explicar por qué el modelo puede resolver tareas no vistas explícitamente.

Por qué importa para el TFG: Tus casos de prueba estarán basados en prompts. Por eso necesitas entender que el prompt no es solo una pregunta, sino parte del comportamiento del sistema.

Tema 8. Tokenización, decodificación y variabilidad

Contenidos teóricos

- Token.
- Tokenización por subpalabras.
- Byte Pair Encoding.
- WordPiece.
- SentencePiece.
- Distribución de probabilidad de salida.
- Greedy decoding.
- Beam search.
- Sampling.
- Top-k.
- Top-p.
- Temperatura.
- Variabilidad de respuestas.
- Reproducibilidad.

Contenidos prácticos

- Tokenizar frases sencillas.
- Comparar una respuesta con temperatura baja y alta.
- Explicar por qué una misma pregunta puede generar respuestas distintas.

Por qué importa para el TFG: Justifica por qué el testing de LLMs no puede basarse siempre en una única salida esperada exacta.

Tema 9. Alineamiento e instrucción

Contenidos teóricos

- Instruction tuning.
- Fine-tuning supervisado.

- RLHF.
- RLAIIF.
- Constitutional AI.
- Preferencias humanas.
- Seguridad de contenido.
- Moderación.
- Conflictos entre utilidad y seguridad.
- Limitaciones del alineamiento.

Personas, empresas y fechas clave

Año	Hito / Modelo	Persona / Entidad / Relevancia
2022	InstructGPT	OpenAI
2022	ChatGPT	OpenAI
2022-2023	Constitutional AI	Anthropic

Contenidos prácticos

- Comparar una respuesta de modelo base con una respuesta de asistente alineado.
- Identificar cuándo una respuesta prioriza seguridad frente a utilidad.
- Diseñar un prompt que evalúe seguimiento de instrucciones.

Por qué importa para el TFG: Los chatbots educativos no son solo LLMs que completan texto: están alineados para seguir instrucciones y evitar ciertos comportamientos. Eso también debe evaluarse.

Módulo 5. Sistemas conversacionales basados en LLMs

Tema 10. Arquitectura de un chatbot moderno

Contenidos teóricos

- Modelo base.
- Interfaz conversacional.
- Prompt del sistema.
- Prompt del desarrollador.
- Prompt del usuario.
- Historial de conversación.
- Memoria.
- Filtros de seguridad.
- Herramientas externas.
- Moderación de entrada y salida.
- Respuesta final observable.

Contenidos prácticos

- Dibujar la arquitectura funcional de un chatbot.
- Diferenciar modelo, producto y aplicación.
- Identificar qué parte del sistema se evalúa en caja negra.

Por qué importa para el TFG: Tu metodología no evaluará los pesos internos del modelo, sino el comportamiento observable del sistema conversacional.

Tema 11. RAG y sistemas aumentados con recuperación

Contenidos teóricos

- Retrieval-Augmented Generation.
- Embeddings documentales.
- Bases vectoriales.
- Recuperación semántica.
- Generación condicionada por documentos.
- Citas y trazabilidad.
- Errores de recuperación.
- Alucinaciones en RAG.
- Evaluación de sistemas RAG.
- Uso educativo con apuntes, PDFs o manuales.

Contenidos prácticos

- Diseñar un flujo RAG básico.
- Analizar qué puede fallar en recuperación y qué puede fallar en generación.
- Crear un caso de prueba para comprobar si el sistema inventa información fuera de los documentos.

Por qué importa para el TFG: Aunque no implementes RAG, muchos chatbots educativos reales funcionan con documentos. Tu metodología puede mencionar que sería aplicable también a este tipo de sistemas.

Tema 12. Agentes y uso de herramientas

Contenidos teóricos

- Tool use.
- Function calling.
- Agentes basados en LLMs.
- Planificación.
- Ejecución de acciones.
- APIs externas.
- Riesgo de exceso de agencia.
- Validación de salidas.
- Supervisión humana.

Contenidos prácticos

- Identificar riesgos de un chatbot que puede ejecutar acciones.
- Diseñar una prueba para comprobar si el sistema pide confirmación antes de actuar.
- Relacionar tool use con seguridad.

Por qué importa para el TFG: Te ayuda a delimitar el alcance: tu TFG puede centrarse en chatbots educativos de respuesta textual, dejando agentes autónomos fuera del alcance.

Módulo 6. Testing de software como base metodológica

Tema 13. Fundamentos de testing

Contenidos teóricos

- Testing.
- Verificación.

- Validación.
- Caso de prueba.
- Entrada.
- Resultado esperado.
- Criterio de aceptación.
- Oráculo de prueba.
- Defecto.
- Fallo.
- Error.
- Trazabilidad.

Contenidos prácticos

- Crear casos de prueba para una función tradicional.
- Identificar entrada, salida esperada y criterio de aceptación.
- Comparar ese caso con un prompt para LLM.

Por qué importa para el TFG: Tu metodología hereda la lógica del testing clásico, pero la adapta a salidas generativas.

Tema 14. Técnicas de diseño de pruebas

Contenidos teóricos

- Caja negra.
- Caja blanca.
- Particiones de equivalencia.
- Valores límite.
- Tablas de decisión.
- Pruebas basadas en riesgo.
- Pruebas exploratorias.
- Pruebas de regresión.
- Pruebas adversariales.
- Pruebas no funcionales.

Contenidos prácticos

- Clasificar tus pruebas de LLM como caja negra.
- Diseñar prompts a partir de clases de riesgo.
- Crear pruebas normales y pruebas adversariales.

Por qué importa para el TFG: Te permite presentar tu metodología como una adaptación de técnicas de testing ya conocidas.

Tema 15. Calidad del software y modelos de calidad

Contenidos teóricos

- Calidad funcional.
- Fiabilidad.
- Usabilidad.
- Seguridad.
- Mantenibilidad.
- Compatibilidad.

- Portabilidad.
- ISO/IEC 25010.
- Adaptación de modelos de calidad a IA.
- Limitaciones de las normas tradicionales.

Contenidos prácticos

- Relacionar características de ISO/IEC 25010 con dimensiones de evaluación de LLMs.
- Diferenciar calidad software de calidad de respuesta.
- Proponer dimensiones específicas para chatbots educativos.

Por qué importa para el TFG: Te da una base formal para decir que evaluar un chatbot no es solo medir si responde, sino su calidad como sistema interactivo.

Módulo 7. Testing específico de LLMs

Tema 16. Diferencias entre testing tradicional y testing de LLMs

Contenidos teóricos

- Salidas deterministas frente a salidas probabilísticas.
- Salidas cerradas frente a salidas abiertas.
- Oráculo exacto frente a oráculo difuso.
- Variabilidad.
- Dependencia del prompt.
- Dependencia del contexto.
- Respuestas parcialmente correctas.
- Evaluación por grados.
- Necesidad de rúbricas.
- Dificultad de reproducibilidad.

Contenidos prácticos

- Ejecutar el mismo prompt varias veces y comparar respuestas.
- Evaluar una respuesta parcialmente correcta.
- Diseñar criterios para una pregunta con varias respuestas válidas.

Por qué importa para el TFG: Este tema es el núcleo de la justificación metodológica.

Tema 17. Evaluación multidimensional de LLMs

Contenidos teóricos

- Corrección factual.
- Relevancia.
- Coherencia.
- Robustez.
- Seguridad.
- Sesgos.
- Toxicidad.
- Calibración.
- Eficiencia.
- Utilidad.
- HELM.

- Benchmarks holísticos.

Contenidos prácticos

- Evaluar una respuesta desde varias dimensiones.
- Comprobar que una respuesta puede ser clara pero incorrecta.
- Comprobar que una respuesta puede ser correcta pero poco útil.

Por qué importa para el TFG: Tu metodología será multidimensional. No basta con decir “bien” o “mal”.

Tema 18. Red teaming y pruebas adversariales

Contenidos teóricos

- Concepto de red teaming.
- Prompts adversariales.
- Jailbreaks.
- Prompt injection.
- Evasión de políticas.
- Ataques indirectos.
- Pruebas de seguridad.
- Evaluación de límites del sistema.
- Riesgos educativos: copia, plagio, manipulación.
- Diferencia entre robustez y seguridad.

Contenidos prácticos

- Diseñar prompts que intenten provocar una respuesta insegura.
- Crear casos de prueba para copia académica.
- Evaluar si el sistema redirige hacia un uso adecuado.

Por qué importa para el TFG: Incluye la dimensión de seguridad y evita que tu metodología sea solo de calidad textual.

Módulo 8. Riesgos y limitaciones de los LLMs

Tema 19. Alucinaciones

Contenidos teóricos

- Definición.
- Alucinaciones factuales.
- Alucinaciones bibliográficas.
- Alucinaciones conceptuales.
- Alucinaciones numéricas.
- Alucinaciones contextuales.
- Causas probables.
- Riesgo de autoridad aparente.
- Detección.
- Mitigación.

Contenidos prácticos

- Diseñar prompts sobre conceptos inventados.
- Pedir referencias académicas inexistentes.
- Puntuar una respuesta que inventa fuentes.

Por qué importa para el TFG: En educación, las alucinaciones son uno de los riesgos más graves.

Tema 20. Errores factuales, conceptuales y de razonamiento

Contenidos teóricos

- Error factual.
- Error conceptual.
- Error de razonamiento.
- Error matemático.
- Error por omisión.
- Error de simplificación excesiva.
- Error de nivel educativo.
- Respuestas parcialmente correctas.
- Corrección frente a utilidad.
- Verificación.

Contenidos prácticos

- Evaluar una explicación técnica.
- Detectar omisiones importantes.
- Diseñar prompts de resolución paso a paso.

Por qué importa para el TFG: Tu metodología debe distinguir entre una respuesta falsa, una incompleta y una correcta pero poco didáctica.

Tema 21. Sesgos, equidad y neutralidad

Contenidos teóricos

- Sesgos en datos.
- Sesgos en entrenamiento.
- Sesgos en alineamiento.
- Estereotipos.
- Fairness.
- Toxicidad.
- Lenguaje discriminatorio.
- Neutralidad.
- Sesgos en educación.
- Evaluación mediante prompts sensibles.

Contenidos prácticos

- Diseñar prompts que puedan provocar estereotipos.
- Evaluar si la respuesta evita generalizaciones.
- Crear criterios de puntuación para neutralidad.

Por qué importa para el TFG: Un chatbot educativo debe evitar reforzar prejuicios o tratar de forma desigual a estudiantes.

Tema 22. Seguridad, privacidad y uso indebido

Contenidos teóricos

- Seguridad de contenido.
- Prompt injection.

- Insecure output handling.
- Divulgación de información sensible.
- Datos personales.
- Plagio.
- Copia académica.
- Ayuda indebida en exámenes.
- Exceso de agencia.
- OWASP Top 10 for LLM Applications.

Contenidos prácticos

- Crear prompts de copia académica.
- Diseñar pruebas de rechazo seguro.
- Evaluar si el chatbot ofrece alternativas educativas.

Por qué importa para el TFG: La seguridad en educación no se limita a violencia o ilegalidad; también incluye integridad académica.

Tema 23. Robustez, incertidumbre y calibración

Contenidos teóricos

- Robustez ante ruido.
- Robustez ante ambigüedad.
- Robustez ante reformulaciones.
- Robustez ante contexto largo.
- Robustez multilingüe.
- Incertidumbre.
- Calibración.
- Sobreconfianza.
- Reconocimiento de límites.
- Respuestas responsables.

Contenidos prácticos

- Plantear preguntas ambiguas.
- Reformular una misma pregunta de varias maneras.
- Evaluar si el sistema dice que no tiene información suficiente.

Por qué importa para el TFG: Un buen chatbot educativo no solo debe responder bien; también debe saber cuándo no puede responder con seguridad.

Módulo 9. LLMs en contextos educativos

Tema 24. Aplicaciones educativas de los LLMs

Contenidos teóricos

- Tutoría conversacional.
- Resolución de dudas.
- Explicación de conceptos.
- Generación de ejemplos.
- Generación de ejercicios.
- Corrección de respuestas.

- Feedback personalizado.
- Resumen de contenidos.
- Apoyo en programación.
- Preparación de exámenes.

Contenidos prácticos

- Clasificar tareas educativas que puede realizar un chatbot.
- Diseñar prompts educativos realistas.
- Identificar tareas de alto y bajo riesgo.

Por qué importa para el TFG: Define el contexto de uso de tu metodología.

Tema 25. Calidad pedagógica de las respuestas

Contenidos teóricos

- Claridad.
- Orden lógico.
- Adecuación al nivel.
- Uso de ejemplos.
- Explicación paso a paso.
- Feedback formativo.
- Fomento de autonomía.
- Evitar dependencia.
- Evitar aprendizaje superficial.
- Adaptación al estudiante.

Contenidos prácticos

- Comparar una respuesta correcta pero mala pedagógicamente con una buena respuesta educativa.
- Diseñar una rúbrica de claridad didáctica.
- Evaluar si una respuesta favorece el aprendizaje.

Por qué importa para el TFG: Tu metodología es educativa, así que debe evaluar utilidad para aprender, no solo exactitud.

Tema 26. Riesgos educativos específicos

Contenidos teóricos

- Plagio.
- Copia.
- Delegación del razonamiento.
- Aprendizaje pasivo.
- Dependencia excesiva.
- Falta de pensamiento crítico.
- Información incorrecta asumida como válida.
- Desigualdad de acceso.
- Privacidad de menores o estudiantes.
- Supervisión docente.

Contenidos prácticos

- Crear casos de prueba de integridad académica.

- Evaluar si el sistema guía en vez de resolver directamente.
- Definir niveles de riesgo educativo.

Por qué importa para el TFG: Da sentido a que tu metodología esté centrada en educación y no en chatbots genéricos.

Módulo 10. Métodos de evaluación de LLMs

Tema 27. Benchmarks y evaluación automática

Contenidos teóricos

- Benchmark.
- MMLU.
- BIG-bench.
- HELM.
- TruthfulQA.
- HumanEval.
- GSM8K.
- Accuracy.
- Exact match.
- F1.
- BLEU.
- ROUGE.
- BERTScore.
- Perplexity.
- Limitaciones de métricas automáticas.

Contenidos prácticos

- Analizar qué mide y qué no mide un benchmark.
- Comparar una métrica automática con una evaluación humana.
- Justificar por qué tu TFG usará rúbrica manual.

Por qué importa para el TFG: Te permite explicar que existen métricas automáticas, pero que no bastan para evaluar calidad educativa.

Tema 28. Evaluación humana y rúbricas

Contenidos teóricos

- Evaluación humana.
- Evaluación experta.
- Rúbricas analíticas.
- Rúbricas holísticas.
- Escalas 0-3.
- Escalas Likert.
- Evaluación ciega.
- Acuerdo entre evaluadores.
- Subjetividad.
- Justificación de puntuaciones.
- Fallos críticos.

Contenidos prácticos

- Diseñar una rúbrica.
- Evaluar la misma respuesta con distintas dimensiones.
- Justificar una puntuación de forma breve y objetiva.

Por qué importa para el TFG: Esta será una de las herramientas centrales de tu metodología.

Tema 29. LLM-as-a-judge y evaluación asistida por IA

Contenidos teóricos

- Concepto de LLM-as-a-judge.
- Evaluación automática mediante modelos.
- Ventajas.
- Riesgos.
- Sesgo hacia respuestas largas.
- Sesgo del propio modelo.
- Falta de criterio experto.
- Uso como apoyo.
- Validación humana.
- Limitaciones.

Contenidos prácticos

- Comparar una evaluación humana con una evaluación generada por IA.
- Identificar errores del juez automático.
- Justificar por qué no se usará como única fuente de evaluación.

Por qué importa para el TFG: Puede aparecer como opción metodológica, aunque para tu caso sea mejor una evaluación manual estructurada.

Módulo 11. Marcos de riesgo, seguridad y gobernanza

Tema 30. NIST AI Risk Management Framework y GenAI

Contenidos teóricos

- Gestión del riesgo en IA.
- Identificación de riesgos.
- Medición.
- Mitigación.
- Gobernanza.
- Riesgos específicos de IA generativa.
- Transparencia.
- Supervisión humana.
- Fiabilidad.
- Seguridad.

Contenidos prácticos

- Relacionar riesgos de NIST con dimensiones de tu metodología.
- Construir una tabla riesgo-dimensión-prueba.
- Clasificar riesgos por impacto.

Por qué importa para el TFG: Aporta una base formal para hablar de riesgo en IA generativa.

Tema 31. OWASP Top 10 for LLM Applications

Contenidos teóricos

- Prompt injection.
- Sensitive information disclosure.
- Supply chain vulnerabilities.
- Data and model poisoning.
- Improper output handling.
- Excessive agency.
- System prompt leakage.
- Vector and embedding weaknesses.
- Misinformation.
- Unbounded consumption.

Contenidos prácticos

- Diseñar casos de prueba de prompt injection.
- Evaluar divulgación de información sensible.
- Relacionar misinformation con alucinaciones educativas.

Por qué importa para el TFG: Te permite incluir una dimensión de seguridad bien justificada.

Tema 32. Ética y regulación básica

Contenidos teóricos

- Transparencia.
- Responsabilidad.
- Supervisión humana.
- Privacidad.
- Datos personales.
- Equidad.
- Integridad académica.
- Uso responsable.
- IA confiable.
- Regulación europea de IA.

Contenidos prácticos

- Identificar riesgos éticos en un chatbot educativo.
- Diseñar recomendaciones de uso responsable.
- Delimitar qué datos no deberían introducirse en un chatbot.

Por qué importa para el TFG: No será el bloque central, pero completa la visión técnica con responsabilidad y uso real.

Módulo 12. Diseño de la metodología del TFG

Tema 33. Definición del objeto de evaluación

Contenidos teóricos

- Sistema conversacional basado en LLM.
- Contexto educativo.
- Evaluación de caja negra.

- Evaluación externa.
- Sistema de acceso público.
- Limitaciones de no conocer arquitectura interna.
- Registro de condiciones de prueba.
- Alcance y exclusiones.

Contenidos prácticos

- Redactar el objeto de evaluación.
- Delimitar qué se evalúa y qué no.
- Elegir un chatbot para aplicación demostrativa.

Tema 34. Dimensiones de evaluación

Contenidos teóricos

- Corrección factual.
- Corrección conceptual.
- Claridad didáctica.
- Relevancia.
- Completitud.
- Seguimiento de instrucciones.
- Coherencia interna.
- Coherencia contextual.
- Control de alucinaciones.
- Reconocimiento de límites.
- Seguridad.
- Sesgos y neutralidad.
- Utilidad educativa.
- Adecuación al nivel.
- Verificabilidad.

Contenidos prácticos

- Seleccionar dimensiones finales.
- Fusionar dimensiones redundantes.
- Definir cada dimensión con criterios observables.

Tema 35. Diseño de rúbrica

Contenidos teóricos

- Rúbrica analítica.
- Escala 0-3.
- Niveles de desempeño.
- Descriptores.
- Criterios observables.
- Fallos críticos.
- Justificación de puntuaciones.
- Subjetividad.
- Doble evaluación.
- Revisión piloto.

Contenidos prácticos

- Crear rúbrica 0-3 para cada dimensión.
- Probar la rúbrica con respuestas reales.
- Ajustar criterios ambiguos.

Tema 36. Diseño de casos de prueba basados en prompts

Contenidos teóricos

- Prompt como entrada de prueba.
- Caso de prueba.
- Objetivo.
- Resultado esperado.
- Dimensión evaluada.
- Riesgo asociado.
- Nivel de riesgo.
- Prompt normal.
- Prompt adversarial.
- Prompt multi-turno.
- Prompt ambiguo.
- Prompt con premisa falsa.

Contenidos prácticos

- Crear una batería inicial de 30 casos.
- Clasificar casos por dimensión.
- Revisar equilibrio entre categorías.

Tema 37. Procedimiento de aplicación y registro

Contenidos teóricos

- Selección del sistema.
- Fecha de evaluación.
- Configuración conocida.
- Ejecución controlada.
- Registro literal de prompts.
- Registro literal de respuestas.
- Evaluación con rúbrica.
- Justificación.
- Tabla de resultados.
- Análisis por dimensión.

Contenidos prácticos

- Diseñar plantilla de registro.
- Ejecutar prueba piloto.
- Guardar resultados de forma trazable.

Tema 38. Métricas e interpretación de resultados

Contenidos teóricos

- Puntuación por caso.

- Puntuación por dimensión.
- Media global.
- Porcentaje de cumplimiento.
- Tasa de fallos críticos.
- Distribución de errores.
- Comparación entre dimensiones.
- Nivel de riesgo.
- Interpretación educativa.
- Limitaciones estadísticas.

Contenidos prácticos

- Calcular medias por dimensión.
- Detectar dimensiones débiles.
- Redactar conclusiones a partir de resultados.

Módulo 13. Aplicación demostrativa y defensa del trabajo

Tema 39. Prueba piloto

Contenidos teóricos

- Objetivo de la prueba piloto.
- Validación de la rúbrica.
- Detección de prompts mal diseñados.
- Ajuste de dimensiones.
- Ajuste de escala.
- Revisión de criterios.

Contenidos prácticos

- Ejecutar 5-10 prompts iniciales.
- Revisar si la rúbrica permite evaluar bien.
- Modificar lo necesario antes de la aplicación completa.

Tema 40. Aplicación completa

Contenidos teóricos

- Ejecución de batería completa.
- Evaluación manual estructurada.
- Análisis cuantitativo.
- Análisis cualitativo.
- Ejemplos representativos.
- Fallos críticos.
- Discusión.
- Limitaciones.
- Trabajo futuro.

Contenidos prácticos

- Aplicar la batería final.
- Elaborar tablas y gráficos.
- Redactar análisis de resultados.

- Preparar conclusiones defendibles.

Distribución recomendada como asignatura

Semana	Contenido
1	Orígenes de IA, NLP y chatbots clásicos
2	NLP estadístico y representaciones clásicas
3	Embeddings y deep learning para lenguaje
4	RNN, LSTM y limitaciones del procesamiento secuencial
5	Transformer y mecanismo de atención
6	BERT, GPT y evolución de los LLMs
7	Tokenización, decodificación, prompting y variabilidad
8	Alineamiento, ChatGPT y arquitectura de chatbots modernos
9	Testing tradicional de software
10	Testing específico de LLMs y problema del oráculo
11	Riesgos: alucinaciones, sesgos, seguridad, robustez
12	LLMs en educación y calidad didáctica
13	Evaluación de LLMs: benchmarks, rúbricas y evaluación humana
14	Diseño de metodología: dimensiones, casos de prueba, métricas y aplicación

Evaluación de la asignatura ficticia

Actividad	Peso
Cuestionarios teóricos sobre LLMs y testing	20 %
Prácticas de prompting y análisis de respuestas	20 %
Diseño de rúbrica de evaluación	20 %
Diseño de batería de casos de prueba	20 %
Aplicación final a un chatbot educativo	20 %

Prácticas asociadas

Práctica 1. Comparación entre NLP clásico y LLMs

Objetivo: entender la diferencia entre representación textual tradicional y generación contextual.

Práctica 2. Análisis de prompts

Objetivo: comprobar cómo cambia una respuesta según la formulación del prompt.

Práctica 3. Detección de alucinaciones

Objetivo: diseñar prompts que permitan identificar invención de datos o referencias.

Práctica 4. Testing de instrucciones

Objetivo: comprobar si un chatbot respeta formato, longitud, idioma y restricciones.

Práctica 5. Diseño de rúbrica

Objetivo: construir una escala de evaluación 0-3 para respuestas generadas por IA.

Práctica 6. Batería de casos de prueba

Objetivo: crear un conjunto equilibrado de prompts para evaluar distintas dimensiones.

Práctica 7. Aplicación piloto

Objetivo: ejecutar algunos casos reales, registrar respuestas y ajustar la metodología.

Bibliografía base de la asignatura

Lecturas técnicas principales

1. Turing, A. M. - Computing Machinery and Intelligence.
2. Vaswani et al. - Attention Is All You Need.
3. Devlin et al. - BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
4. Brown et al. - Language Models are Few-Shot Learners.
5. Ouyang et al. - Training language models to follow instructions with human feedback.
6. Liang et al. - Holistic Evaluation of Language Models.
7. NIST - Artificial Intelligence Risk Management Framework.
8. OWASP - Top 10 for Large Language Model Applications.
9. ISO/IEC 25010 - Modelo de calidad del producto software.