

Índice provisional del Trabajo de Fin de Grado

Testing de sistemas conversacionales basados en LLMs en contextos educativos

Fecha: 6 de julio de 2026

1. Introducción

1.1. Contexto y motivación

Presentación del crecimiento de la inteligencia artificial generativa y de los modelos de lenguaje de gran tamaño en los últimos años, especialmente en herramientas conversacionales como asistentes virtuales o chatbots educativos.

1.2. Planteamiento del problema

Explicación de la dificultad de evaluar sistemas basados en LLMs, debido a la variabilidad de sus respuestas, la posibilidad de generar información incorrecta, las alucinaciones, los sesgos, el incumplimiento de instrucciones y los riesgos derivados de su uso en contextos educativos.

1.3. Justificación del trabajo

Justificación de la necesidad de diseñar una metodología de testing específica para este tipo de sistemas, diferente al testing tradicional de software, y orientada a evaluar la calidad, fiabilidad, seguridad y utilidad de las respuestas generadas.

1.4. Objetivos del trabajo

Presentación del objetivo general y de los objetivos específicos del TFG.

1.5. Preguntas de investigación

Presentación de la pregunta principal de investigación y de las preguntas secundarias que guían el desarrollo del trabajo.

1.6. Alcance y limitaciones iniciales

Delimitación del trabajo: se centrará en sistemas conversacionales basados en LLMs aplicados a contextos educativos o de asistencia al aprendizaje. No se abordará el desarrollo de un modelo propio ni la evaluación interna del entrenamiento del modelo.

1.7. Estructura del documento

Breve explicación de cómo está organizada la memoria del TFG.

2. Marco teórico

2.1. Inteligencia artificial generativa

Definición de IA generativa y explicación de su capacidad para crear contenido nuevo a partir de datos y patrones aprendidos.

2.2. Modelos de lenguaje de gran tamaño

Explicación general de qué son los LLMs, cómo procesan el lenguaje y cómo generan respuestas en sistemas conversacionales.

2.3. Chatbots basados en LLMs

Descripción del funcionamiento general de los chatbots basados en modelos de lenguaje: entrada del usuario, procesamiento del prompt, contexto conversacional y generación de respuesta.

2.4. Uso de LLMs en contextos educativos

Análisis de las posibilidades de uso de estos sistemas en educación: explicación de conceptos, resolución de dudas, apoyo al estudio, resumen de contenidos o generación de ejemplos.

2.5. Riesgos y limitaciones de los LLMs

Descripción de los principales problemas asociados a estos sistemas: alucinaciones, errores factuales, sesgos, falta de trazabilidad, sobreconfianza, dependencia del prompt, problemas de seguridad y dificultad para reconocer incertidumbre.

3. Testing de sistemas basados en LLMs

3.1. Testing tradicional de software

Breve explicación del testing clásico: casos de prueba, entradas, salidas esperadas, criterios de aceptación y detección de errores.

3.2. Diferencias entre el testing tradicional y el testing de LLMs

Comparación entre ambos enfoques, destacando que los sistemas basados en LLMs generan respuestas abiertas, variables y difíciles de evaluar con criterios binarios de correcto/incorrecto.

3.3. Evaluación de respuestas generadas por IA

Explicación de la necesidad de utilizar rúbricas, evaluación humana, criterios cualitativos y métricas adaptadas a sistemas generativos.

3.4. Benchmarks y métodos de evaluación existentes

Revisión general de métodos utilizados para evaluar LLMs, como benchmarks, pruebas de razonamiento, evaluación humana, red teaming o pruebas de robustez.

3.5. Necesidad de una metodología específica para contextos educativos

Justificación de por qué un chatbot educativo requiere criterios propios, relacionados con la corrección, claridad, utilidad pedagógica y seguridad en el aprendizaje.

4. Propuesta metodológica

4.1. Descripción general de la metodología

Presentación de la metodología propuesta para evaluar chatbots educativos basados en LLMs.

4.2. Dimensiones de evaluación

Definición de las dimensiones que se tendrán en cuenta para evaluar las respuestas del sistema, como corrección factual, relevancia, claridad didáctica, seguimiento de instrucciones, coherencia contextual, seguridad, control de alucinaciones, reconocimiento de límites y utilidad educativa.

4.3. Rúbrica de evaluación

Diseño de una rúbrica para puntuar las respuestas generadas por el sistema, utilizando una escala estructurada que permita diferenciar entre respuestas incorrectas, incompletas, aceptables y adecuadas.

4.4. Diseño de casos de prueba

Explicación de cómo se construirán los casos de prueba a partir de prompts representativos de situaciones educativas.

4.5. Clasificación de los casos de prueba

Organización de los casos de prueba según las dimensiones evaluadas: corrección factual, alucinaciones, seguimiento de instrucciones, robustez, seguridad, sesgos, coherencia contextual y utilidad educativa.

4.6. Procedimiento de aplicación

Descripción de los pasos para aplicar la metodología: selección del sistema, ejecución de prompts, registro de respuestas, evaluación mediante la rúbrica, análisis de resultados y detección de riesgos.

4.7. Métricas e interpretación de resultados

Definición de métricas sencillas, como puntuación media por dimensión, porcentaje de cumplimiento, número de fallos críticos y análisis cualitativo de los errores detectados.

5. Aplicación demostrativa de la metodología

5.1. Selección del sistema evaluado

Descripción del sistema conversacional basado en LLM que se utilizará como ejemplo de aplicación de la metodología.

5.2. Condiciones de la evaluación

Indicación de la fecha de realización de las pruebas, versión o características conocidas del sistema, número de prompts utilizados y criterios seguidos durante la evaluación.

5.3. Ejecución de los casos de prueba

Presentación de los casos de prueba aplicados y registro de las respuestas obtenidas.

5.4. Evaluación de las respuestas

Aplicación de la rúbrica a las respuestas generadas por el sistema.

5.5. Resultados obtenidos

Presentación de los resultados por dimensión de evaluación, mediante tablas, gráficos o análisis descriptivo.

5.6. Análisis de errores y riesgos detectados

Identificación de los principales fallos encontrados, como errores factuales, respuestas incompletas, alucinaciones, incumplimiento de instrucciones o problemas de utilidad educativa.

6. Discusión

6.1. Interpretación general de los resultados

Análisis de lo que muestran los resultados obtenidos durante la aplicación demostrativa.

6.2. Fortalezas de la metodología propuesta

Explicación de los aspectos positivos de la metodología: estructura clara, aplicabilidad, adaptación al contexto educativo y posibilidad de detectar distintos tipos de riesgos.

6.3. Limitaciones del trabajo

Reconocimiento de las limitaciones del TFG, como el número reducido de pruebas, la posible subjetividad en la evaluación, la variabilidad de los modelos y la dependencia del sistema concreto utilizado.

6.4. Comparación con enfoques existentes

Relación entre la metodología propuesta y otros métodos de evaluación de LLMs revisados en el estado del arte.

6.5. Posibles mejoras

Propuesta de mejoras futuras, como ampliar la batería de casos, incluir más evaluadores humanos, comparar varios modelos o automatizar parte del proceso de evaluación.

7. Conclusiones

7.1. Conclusiones principales

Resumen de las principales aportaciones del trabajo y respuesta a la pregunta de investigación.

7.2. Cumplimiento de objetivos

Revisión de los objetivos planteados y explicación de cómo se han abordado a lo largo del TFG.

7.3. Aportaciones del trabajo

Descripción del valor de la propuesta metodológica como herramienta para evaluar chatbots educativos basados en LLMs.

7.4. Trabajo futuro

Líneas de continuación, como la aplicación de la metodología a más sistemas, la mejora de las rúbricas o la integración con herramientas automáticas de evaluación.

8. Bibliografía

Listado de las fuentes académicas, técnicas y normativas utilizadas para fundamentar el trabajo.

9. Anexos

Anexo I. Rúbrica completa de evaluación

Inclusión de la rúbrica detallada utilizada para puntuar las respuestas.

Anexo II. Batería de casos de prueba

Listado completo de los prompts diseñados para evaluar el sistema.

Anexo III. Respuestas obtenidas

Registro de las respuestas generadas por el sistema evaluado durante la aplicación demostrativa.

Anexo IV. Tablas de resultados

Tablas con las puntuaciones asignadas a cada respuesta y los resultados agregados por dimensión.