

Objetivos del Trabajo de Fin de Grado

Propuesta metodológica para el testing de sistemas conversacionales basados en LLMs en contextos educativos

6 de julio de 2026

1. Objetivo general

El objetivo general de este Trabajo de Fin de Grado es diseñar una metodología de testing para evaluar sistemas conversacionales basados en modelos de lenguaje de gran tamaño -LLMs- en contextos educativos o de asistencia al aprendizaje. Esta metodología estará orientada a analizar la calidad, fiabilidad, seguridad y utilidad de las respuestas generadas por este tipo de sistemas, teniendo en cuenta sus características específicas y sus diferencias respecto al software tradicional.

2. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

1. Analizar las características principales de los modelos de lenguaje de gran tamaño y su aplicación en sistemas conversacionales de IA generativa.
2. Estudiar las diferencias entre el testing de software tradicional y la evaluación de sistemas basados en LLMs, especialmente en relación con la variabilidad de las respuestas, la dificultad para definir resultados esperados cerrados y la necesidad de evaluación mediante criterios cualitativos.
3. Identificar los principales riesgos asociados al uso de chatbots basados en LLMs en contextos educativos, como la generación de información incorrecta, las alucinaciones, la falta de reconocimiento de incertidumbre, los sesgos, el incumplimiento de instrucciones o la generación de respuestas poco adecuadas para el aprendizaje.
4. Definir un conjunto de dimensiones de evaluación que permitan valorar de forma sistemática las respuestas generadas por estos sistemas, incluyendo aspectos como la corrección factual, la claridad didáctica, la relevancia, la coherencia, el seguimiento de instrucciones, la seguridad y la utilidad educativa.
5. Diseñar una rúbrica de evaluación que permita puntuar las respuestas del sistema de forma estructurada, estableciendo criterios claros para diferenciar entre respuestas incorrectas, incompletas, aceptables y adecuadas.

6. Elaborar una batería de casos de prueba basada en prompts representativos de situaciones educativas, con el fin de evaluar el comportamiento del sistema ante distintos tipos de tareas, preguntas y escenarios de uso.
7. Proponer un procedimiento de aplicación de la metodología, incluyendo la ejecución de los casos de prueba, el registro de las respuestas, la puntuación mediante la rúbrica y la interpretación de los resultados obtenidos.
8. Aplicar la metodología de forma demostrativa sobre uno o varios sistemas conversacionales basados en LLMs de acceso público, con el objetivo de comprobar su viabilidad y mostrar cómo podrían analizarse los resultados.
9. Identificar las principales fortalezas, limitaciones y riesgos detectados durante la aplicación de la metodología, proponiendo posibles mejoras o líneas de trabajo futuro.

3. Pregunta principal de investigación

La pregunta principal que guía este Trabajo de Fin de Grado es la siguiente:

¿Cómo puede diseñarse una metodología de testing que permita evaluar de forma sistemática la calidad, fiabilidad, seguridad y utilidad de sistemas conversacionales basados en LLMs en contextos educativos o de asistencia al aprendizaje?

4. Preguntas secundarias

A partir de la pregunta principal, se plantean también las siguientes preguntas secundarias:

1. ¿Qué características de los sistemas basados en LLMs hacen que su evaluación sea diferente al testing de software tradicional?
2. ¿Qué riesgos específicos presentan los chatbots basados en LLMs cuando se utilizan en contextos educativos?
3. ¿Qué dimensiones deben tenerse en cuenta para evaluar la calidad de las respuestas generadas por un sistema conversacional educativo?
4. ¿Cómo puede diseñarse una rúbrica que permita valorar respuestas generadas por IA cuando no existe siempre una única respuesta correcta?
5. ¿Qué tipos de prompts o casos de prueba son útiles para detectar errores, alucinaciones, incumplimiento de instrucciones, problemas de seguridad o falta de utilidad educativa?
6. ¿De qué manera pueden interpretarse los resultados obtenidos para identificar fortalezas, debilidades y riesgos del sistema evaluado?

5. Relación con el enfoque elegido

Estos objetivos consolidan el enfoque del TFG como una propuesta metodológica, no como el desarrollo de un chatbot propio. El trabajo se centrará en definir una forma ordenada, justificable y aplicable de evaluar sistemas conversacionales basados en LLMs dentro del ámbito educativo. De esta manera, el valor principal del proyecto estará en la metodología de evaluación, la rúbrica, los casos de prueba y el análisis de resultados.