

Chatbots de Código Abierto Basados en LLM

Este documento resume las principales alternativas de código abierto para desarrollar chatbots basados en grandes modelos de lenguaje (LLMs), así como las herramientas que forman parte de su ecosistema y una arquitectura recomendada para proyectos de investigación como un Trabajo de Fin de Grado.

1. Modelos LLM de código abierto

Meta – Llama 3.x

- Excelente rendimiento general.
- Muy utilizado en investigación y producción.
- Gran comunidad y abundantes modelos derivados.

Enlace: <https://ai.meta.com/llama/>

Mistral AI – Mistral / Mixtral

- Modelos rápidos y eficientes.
- Muy populares por su equilibrio entre calidad y consumo de recursos.

Enlace: <https://mistral.ai/>

Alibaba – Qwen

- Muy potente en razonamiento y programación.
- Disponible en múltiples tamaños.

Enlace: <https://qwenlm.github.io/>

Google – Gemma

- Familia abierta inspirada en Gemini.
- Muy utilizada en investigación.

Enlace: <https://ai.google.dev/gemma>

DeepSeek

- Excelente relación rendimiento/tamaño.
- Muy utilizado para programación y razonamiento.

Enlace: <https://www.deepseek.com/>

2. Interfaces tipo ChatGPT

Estas herramientas proporcionan la interfaz conversacional al usuario, mientras que el modelo LLM se ejecuta por separado. **Open WebUI** – Similar a ChatGPT. Compatible con Ollama, OpenAI y vLLM. <https://openwebui.com/> **LibreChat** – Interfaz moderna con soporte para múltiples modelos. <https://www.librechat.ai/> **AnythingLLM** – Especialmente orientado a sistemas RAG y documentos. <https://anythingllm.com/>

3. Frameworks para construir chatbots

LangChain – <https://www.langchain.com/>

LlamaIndex – <https://www.llamaindex.ai/>

Haystack – <https://haystack.deepset.ai/>

Rasa – <https://rasa.com/>

Estos frameworks permiten integrar LLMs con bases de datos, documentos, APIs, herramientas externas y sistemas RAG.

4. Ejemplos de chatbots completos

Algunas configuraciones habituales son: Open WebUI + Ollama + Llama. LibreChat + Qwen. AnythingLLM + Mistral. Open WebUI + DeepSeek. Con poca configuración es posible disponer de un asistente privado similar a ChatGPT ejecutándose en un ordenador propio.

5. Arquitectura recomendada para un TFG

Una arquitectura ampliamente utilizada en investigación consiste en: Frontend: Open WebUI. Servidor del modelo: Ollama (<https://ollama.com/>). LLM: Llama 3 o Qwen. Base documental (opcional): LlamaIndex o LangChain para implementar RAG. Esta arquitectura permite sustituir el modelo sin modificar la interfaz y facilita la realización de experimentos reproducibles.

6. Utilidad para una metodología de testing

Los chatbots de código abierto permiten controlar toda la arquitectura del sistema y evaluar distintos modelos bajo las mismas condiciones. Esto facilita medir aspectos como: Precisión de las respuestas. Alucinaciones. Robustez frente a entradas complejas. Seguridad. Experiencia de usuario. Por ello constituyen una base muy adecuada para diseñar metodologías de evaluación y testing de chatbots educativos basados en LLM.