

Planificacion temporal actualizada del TFG

Metodologia de testing para chatbots educativos basados en LLM

Fecha de inicio: 8 de agosto de 2026

Fecha objetivo de finalizacion: 20 de octubre de 2026

Disponibilidad: dedicacion parcial hasta el 31 de agosto y dedicacion alta a partir del 1 de septiembre.

El retraso del inicio obliga a cambiar la estrategia original. Durante agosto ya no se separara completamente el estudio del desarrollo: se estudiaran los fundamentos imprescindibles mientras se prepara el entorno experimental. A partir de septiembre, el trabajo se orientara principalmente a producir la metodologia, ejecutar las pruebas, analizar resultados y redactar el TFG.

1. Objetivos globales del proyecto

- Comprender tecnicamente el funcionamiento de los LLM y de un chatbot moderno.
- Conocer las principales alternativas open source y disponer de un chatbot funcional para experimentacion.
- Dominar los fundamentos de testing de software que sean relevantes para sistemas basados en LLM.
- Estudiar los problemas especificos de evaluacion de LLM: alucinaciones, variabilidad, robustez, seguridad, prompt injection, jailbreaks, etc.
- Identificar los requisitos particulares de un chatbot educativo: correccion, claridad, adecuacion pedagogica, feedback, adaptacion al nivel y seguridad.
- Diseñar una metodologia de testing estructurada, reproducible y justificable academicamente.
- Crear una bateria de casos de prueba y rubricas/metricas de evaluacion.
- Aplicar la metodologia sobre un chatbot real y recoger resultados.
- Analizar los resultados, discutir limitaciones y validar la utilidad de la metodologia.
- Redactar, revisar y entregar el TFG completo antes del 20 de octubre.

2. Cronograma general

Periodo	Objetivo principal	Entregable
8-16 agosto	Fundamentos LLM y arquitectura de chatbots	Base tecnica comprendida
17-23 agosto	Chatbot open source y entorno experimental	Chatbot funcionando
24-31 agosto	Testing de software, LLM y contexto educativo	Base teorica esencial
1-7 septiembre	Estado del arte y definicion exacta del TFG	Alcance e indice cerrados
8-14 septiembre	Diseño de la metodologia	Dimensiones, metricas y rubricas
15-21 septiembre	Bateria de pruebas	Casos de prueba terminados
22-28 septiembre	Ejecucion experimental	Datos recogidos
29 sep.-5 oct.	Analisis y redaccion teorica	Resultados + marco teorico
6-12 octubre	Redaccion integral	Primer borrador completo
13-16 octubre	Revision sustantiva	Version casi final
17-20 octubre	Revision final y entrega	TFG terminado

3. Del 8 al 16 de agosto - Fundamentos y arquitectura

Prioridad: adquirir solo la teoria necesaria para poder avanzar tecnicamente.

Estudiar: evolucion y fundamentos de los LLM; tokens y tokenizacion; embeddings; Transformer y mecanismo de atencion; pretraining, instruction tuning y alineamiento; inferencia y parametros de generacion; diferencia entre LLM, chatbot, agente y RAG; arquitectura completa de un chatbot.

Investigar: Llama, Qwen, Mistral, Gemma y DeepSeek; Open WebUI, LibreChat y AnythingLLM; Ollama; LangChain, LlamaIndex y Haystack.

Trabajo del TFG: crear una estructura de carpetas/repositorio, comenzar la bibliografía y registrar desde el principio las fuentes útiles y decisiones técnicas.

Entregable: poder explicar técnicamente el flujo usuario - interfaz - backend - modelo - respuesta y tener seleccionadas las herramientas que se probarán.

4. Del 17 al 23 de agosto - Entorno experimental

Objetivo: disponer de un chatbot real sobre el que experimentar.

Pasos: instalar Ollama; descargar al menos un modelo adecuado; instalar/configurar Open WebUI u otra interfaz elegida; configurar prompt de sistema; realizar conversaciones de prueba; observar temperatura y variabilidad; documentar hardware, versiones, modelo y parámetros para garantizar reproducibilidad.

Opcional si el alcance lo requiere: introducir documentos mediante RAG y comprobar cómo cambia el comportamiento.

Entregable: chatbot local funcional y configuración experimental documentada.

5. Del 24 al 31 de agosto - Testing y contexto educativo

Testing tradicional: QA, verificación y validación, niveles y tipos de prueba, casos de prueba, oráculos, cobertura, automatización, reproducibilidad y métricas.

Testing de LLM: alucinaciones, factualidad, consistencia, variabilidad, robustez, prompts ambiguos/adversariales, prompt injection, jailbreaks, toxicidad, sesgos, seguridad y calidad de respuesta.

Chatbots educativos: corrección conceptual, claridad, adecuación al nivel, capacidad explicativa, feedback, detección de errores del alumno, utilidad pedagógica y comportamiento ante preguntas fuera del dominio.

Entregable del 31 de agosto: teoría esencial estudiada, chatbot funcionando, bibliografía inicial organizada, arquitectura experimental definida y primera lista de dimensiones que podría evaluar la metodología.

6. Del 1 al 7 de septiembre - Estado del arte y alcance definitivo

Revisar literatura científica sobre evaluación de LLM, benchmarks, LLM-as-a-judge, evaluación humana, seguridad y evaluación educativa. Comparar metodologías existentes, detectar sus limitaciones y justificar que aporta la propuesta del TFG.

Cerrar: pregunta/objetivo de investigación, alcance, chatbot y modelo evaluados, contexto educativo, exclusiones, índice provisional definitivo y estrategia experimental.

Entregable: alcance congelado. A partir de este punto se evitarán ampliaciones que pongan en riesgo la fecha de entrega.

7. Del 8 al 14 de septiembre - Diseño completo de la metodología

Definir las dimensiones de calidad. Como punto de partida: exactitud/factualidad, relevancia, claridad, calidad pedagógica, robustez, consistencia, seguridad y manejo de incertidumbre.

Para cada dimensión definir: qué significa, por qué importa, indicador, métrica o rúbrica, escala, criterio de aprobado/fallo, procedimiento de evaluación y limitaciones.

Definir también: número de repeticiones por prompt, parámetros del modelo, control de aleatoriedad, registro de

respuestas, evaluacion humana y/o automatica y forma de agregar resultados.

Fecha critica: el 14 de septiembre la metodologia debe estar conceptualmente cerrada.

8. Del 15 al 21 de septiembre - Bateria de casos de prueba

Crear y clasificar los prompts: preguntas sencillas, complejas, ambiguas, mal formuladas, con errores del alumno, fuera del dominio, contradictorias, largas, adversariales y de seguridad. Incluir pruebas especificas de comportamiento pedagogico.

Preparar para cada caso: identificador, objetivo, categoria, entrada, precondiciones/contexto, comportamiento esperado, dimensiones evaluadas y criterio de puntuacion.

Realizar un pequeño piloto y corregir casos que no midan realmente lo esperado.

Fecha critica: bateria definitiva lista el 21 de septiembre.

9. Del 22 al 28 de septiembre - Ejecucion experimental

Congelar la configuracion antes de empezar. Ejecutar sistematicamente los casos, repetir cuando corresponda, almacenar prompts, respuestas, puntuaciones, tiempos y observaciones. No modificar la metodologia durante la recogida salvo que aparezca un error metodologico grave; cualquier cambio debe quedar documentado.

Entregable: dataset/resultados completos antes del 28 de septiembre.

10. Del 29 de septiembre al 5 de octubre - Analisis y marco teorico

Limpiar y organizar resultados. Calcular puntuaciones por dimension y categoria, analizar fallos, buscar patrones y preparar tablas/figuras. Interpretar los resultados en relacion con los objetivos.

En paralelo, convertir las notas acumuladas en redaccion formal del marco teorico y estado del arte. Mantener las referencias desde el momento de redactar, evitando dejar las citas para el final.

11. Del 6 al 12 de octubre - Primer borrador completo

Redactar e integrar: introduccion y objetivos; contexto y estado del arte; fundamentos; metodologia propuesta; entorno experimental; casos de prueba; resultados; discusion; amenazas a la validez y limitaciones; trabajo futuro; conclusiones; bibliografia y anexos.

Fecha limite interna: 12 de octubre. El TFG debe poder entregarse ya en esta fecha, aunque todavia necesite revision.

12. Del 13 al 16 de octubre - Revision sustantiva

Comprobar coherencia entre objetivos, metodologia, experimentos, resultados y conclusiones. Corregir explicaciones debiles, eliminar redundancias, verificar que todas las decisiones estan justificadas y revisar tablas, figuras, anexos y referencias. Incorporar feedback del tutor si esta disponible.

13. Del 17 al 20 de octubre - Revision final y entrega

Reservar estos dias exclusivamente para contingencias y acabado: ortografia, formato institucional, numeracion, indices, referencias, enlaces, calidad de figuras, portada, anexos, compilacion/exportacion final y comprobacion del PDF.

No introducir nuevas lineas de investigacion en estos cuatro dias salvo que sean imprescindibles para corregir un problema serio.

14. Hitos no negociables

Fecha	Debe estar terminado
23 agosto	Chatbot y entorno experimental funcionando
31 agosto	Base teorica esencial + primera estructura metodologica
7 septiembre	Alcance, estado del arte inicial e indice cerrados
14 septiembre	Metodologia completamente diseñada
21 septiembre	Bateria de pruebas definitiva
28 septiembre	Experimentos terminados
5 octubre	Analisis principal y marco teorico muy avanzado
12 octubre	Primer borrador completo y entregable
16 octubre	Version revisada
20 octubre	Entrega final

15. Reglas de trabajo para proteger el calendario

- No intentar recuperar el retraso estudiando todo con maxima profundidad: distinguir contenido imprescindible de ampliaciones.
- Estudiar y documentar en paralelo. Cada fuente util debe quedar registrada desde el principio.
- No esperar a octubre para redactar: las notas tecnicas, decisiones y justificaciones deben convertirse progresivamente en texto reutilizable.
- Congelar el alcance el 7 de septiembre y la metodologia el 14 de septiembre.
- Mantener una configuracion experimental reproducible: versiones, modelo, parametros, prompts y resultados.
- Priorizar una metodologia bien justificada y validada sobre una implementacion excesivamente compleja.
- Usar el 12 de octubre como fecha real de finalizacion; el 20 de octubre es el margen de seguridad y entrega.

16. Organizacion documental recomendada

Mantener una biblioteca tecnica separada por temas: fundamentos de LLM; arquitectura de chatbots; modelos y herramientas open source; RAG; testing de software; testing y evaluacion de LLM; seguridad; metricas y rubricas; chatbots educativos; articulos del estado del arte; decisiones metodologicas; experimentos y resultados. El objetivo es que la investigacion realizada durante agosto y septiembre pueda convertirse despues en el marco teorico y la justificacion metodologica sin repetir trabajo.