

Resumen Ejecutivo y Guía de Decisiones del Trabajo de Fin de Grado (TFG)

Título: Metodología para testing de IA Generativa de texto en educación

Autor: Marcos Tomás Jiménez Meléndez

Grado: Grado en Ingeniería Informática (UAM / EPS)

Versión experimental de referencia: v1.3.1-tfg

1. Idea central del trabajo

¿Qué problema se intenta resolver?

El problema de partida es de **ingeniería del software**: los mecanismos clásicos de testing funcionan especialmente bien cuando existe un oráculo determinista, es decir, cuando para una entrada concreta existe una salida esperada que puede comprobarse mediante una asección booleana.

En un sistema basado en un Large Language Model (LLM), esa lógica deja de ser suficiente. Ante una misma consulta pueden existir múltiples respuestas válidas en lenguaje natural, con formulaciones diferentes, y la generación depende de un proceso probabilístico. Por tanto, una comprobación del tipo “salida generada = salida esperada” no permite determinar de forma adecuada si una respuesta es correcta, segura o pedagógicamente útil.

En educación el problema es todavía más exigente, porque no basta con comprobar si una respuesta “suena bien” o contiene información relevante. Un chatbot puede:

- producir una respuesta lingüísticamente fluida pero conceptualmente falsa;
- validar una premisa inventada o una referencia inexistente;
- entregar directamente la solución de un ejercicio y sustituir el razonamiento del alumno;
- no detectar el error conceptual que está cometiendo el estudiante;
- utilizar un nivel de complejidad inadecuado;
- incumplir restricciones explícitas;
- ceder ante prompt injection, jailbreaks o peticiones de fraude académico.

Por tanto, el TFG plantea la siguiente pregunta de fondo:

¿Cómo puede auditarse de forma sistemática un chatbot educativo basado en LLMs cuando no existe una única respuesta textual correcta y, además, deben evaluarse simultáneamente calidad conceptual, seguridad y utilidad pedagógica?

2. ¿Para qué se realiza el trabajo y qué aporta?

El objetivo no es crear un nuevo LLM ni entrenar uno desde cero. La aportación consiste en **diseñar y validar preliminarmente una metodología de testing de caja negra para sistemas conversacionales educativos basados en LLMs**.

El trabajo aporta:

1. **Un marco multidimensional de evaluación**, que separa la calidad en siete dimensiones observables en lugar de reducirla a una única medida general.
2. **Una rúbrica analítica 0–3** con descriptores conductuales para convertir respuestas abiertas en puntuaciones comparables.
3. **Una batería estructurada de 42 casos de prueba**, incluyendo casos curriculares, trampas con premisas falsas, restricciones de formato y escenarios adversariales.
4. **Métricas agregadas de calidad y riesgo**, entre ellas medias dimensionales, tasas de cumplimiento, CFR, HR e IQE.
5. **Un criterio Safety-First**, que impide que una puntuación global alta oculte fallos críticos de factualidad, alucinación o seguridad.
6. **Un estudio experimental real** sobre Meta-Llama-3-8B-Instruct con tres perfiles conversacionales distintos.

7. **Un paquete de software en Python** que automatiza la carga de casos, ejecución, agregación, cálculo de métricas, concordancia y visualización.
8. **Un conjunto de datos abierto y trazable**, con los 126 registros de inferencia, evaluaciones y resultados consolidados.
9. **Evidencia empírica de una idea importante de testing**: mejorar la calidad media de una respuesta no implica necesariamente reducir los fallos críticos.

La aportación central no es afirmar que el Tutor Socrático sea “el mejor chatbot educativo” de forma universal. La aportación consiste en mostrar que el marco permite **detectar diferencias, fortalezas y riesgos que quedarían ocultos si únicamente se utilizara una puntuación global**.

3. Objetivo general y preguntas de investigación

Objetivo general

Diseñar, formalizar y evaluar experimentalmente una metodología de testing para sistemas conversacionales basados en LLMs utilizados como apoyo al aprendizaje, capaz de medir:

- corrección factual;
- control de alucinaciones;
- claridad didáctica;
- utilidad pedagógica;
- robustez y seguridad;
- adaptación al nivel educativo;
- seguimiento de instrucciones.

Preguntas de investigación

PI1. ¿Cómo estructurar un protocolo de testing para LLMs que evalúe simultáneamente rigor conceptual y calidad del andamiaje pedagógico mediante criterios observables?

PI2. ¿Hasta qué punto la configuración del System Prompt, comparando una estrategia expositiva directa con otra socrática, condiciona la seguridad, las alucinaciones y la orientación formativa?

PI3. ¿Puede una rúbrica analítica discreta sin punto neutro reducir la ambigüedad del problema del oráculo y producir una concordancia inter-evaluador suficientemente alta en respuestas abiertas?

4. Fundamentos que sostienen la propuesta

La metodología combina dos familias de fundamentos.

4.1. Ingeniería de software y evaluación de LLMs

- ISO/IEC 25010:2023 como referencia para características de calidad de producto.
- ISO/IEC/IEEE 29119-1:2022 para conceptos generales de testing.
- Problema del oráculo en software.
- Literatura sobre alucinaciones, incertidumbre y factualidad.
- Benchmarks y metodologías de evaluación de LLMs como MMLU, TruthfulQA, MT-Bench, Chatbot Arena e IFEval.
- Literatura sobre prompt injection y jailbreaks.

4.2. Fundamentos pedagógicos

- Zona de Desarrollo Próximo de Vygotsky.
- Andamiaje tutorial de Wood, Bruner y Ross.
- Retroalimentación formativa de Hattie y Timperley.
- Taxonomía de Bloom y revisión de Anderson y Krathwohl.

- Concepto de cognitive offloading para justificar el riesgo del solucionismo directo.

La metodología no copia literalmente ninguno de estos marcos. Los utiliza para **construir una adaptación propia orientada al testing de chatbots educativos**.

5. Solución metodológica propuesta

5.1. Siete dimensiones de evaluación

D1 — Corrección Factual y Rigor Conceptual

Comprueba si la información proporcionada es disciplinarmente correcta y suficientemente completa.

D2 — Control de Alucinaciones y Manejo de Incertidumbre

Evalúa si el sistema evita inventar información, valida o rechaza premisas falsas y gestiona correctamente situaciones de incertidumbre.

D3 — Claridad Didáctica y Estructura Explicativa

Valora organización, progresión lógica, comprensibilidad y uso pertinente de ejemplos o analogías.

D4 — Utilidad Pedagógica, Detección de Errores y Feedback

Mide si el chatbot identifica el error real del estudiante y lo orienta mediante pistas o preguntas en lugar de limitarse a proporcionar una solución.

D5 — Robustez, Seguridad e Integridad Académica

Comprueba la resistencia frente a prompt injection, jailbreaks y peticiones de fraude académico.

D6 — Adaptación al Nivel Educativo, Complejidad Cognitiva y Registro

Valora si vocabulario, profundidad y demanda cognitiva se ajustan al nivel del estudiante.

D7 — Seguimiento de Instrucciones y Restricciones

Comprueba restricciones objetivas de formato, longitud, léxico y estructura.

6. Rúbrica de valoración

Se utiliza una escala discreta de cuatro niveles:

- **0 — Crítico / Inaceptable:** fallo grave o incumplimiento esencial.
- **1 — Deficiente / Parcial:** respuesta con problemas importantes o cumplimiento insuficiente.
- **2 — Aceptable / Correcto:** respuesta adecuada aunque mejorable.
- **3 — Excelente / Óptimo:** comportamiento correcto, completo y especialmente sólido respecto al criterio evaluado.

Decisión: eliminar el punto medio neutro

Se eligió una escala par 0–3 para obligar al evaluador a discriminar entre una respuesta insuficiente y una respuesta aceptable, evitando utilizar sistemáticamente una categoría central neutral.

No se afirma que una escala de cuatro niveles sea universalmente superior. Es una **decisión metodológica de esta validación**, acompañada de descriptores conductuales explícitos para reducir la ambigüedad.

Decisión adicional en D1

Para recibir D1 = 3 en casos conceptuales no basta con “no decir nada incorrecto”. La respuesta debe ser también **suficientemente completa respecto a lo solicitado**. Esto evita premiar con la máxima puntuación respuestas que eluden el contenido factual principal.

7. Diseño de la batería de pruebas

Cada caso se representa mediante:

$C_i = \langle \text{id}, \text{dimensión_ppal}, \text{materia}, \text{nivel}, \text{prompt}, \text{ground_truth}, \text{criterio_crítico} \rangle$

La batería contiene **42 casos**, distribuidos de forma equilibrada:

- 7 dimensiones;
- 6 casos cuya dimensión principal corresponde a cada dimensión;
- total: 42 casos.

¿Por qué 42 casos y seis por dimensión?

Se decidió utilizar una distribución simétrica de seis casos por dimensión para:

- garantizar que todas las dimensiones principales estuvieran representadas de forma equivalente;
- facilitar la comparación entre dimensiones;
- mantener un tamaño que permitiera una revisión manual exhaustiva de todas las respuestas.

Se trata de una **validación preliminar**, no de un benchmark masivo.

Tipologías incluidas

La batería incorpora:

- pruebas nominales de conocimiento curricular;
- pruebas de frontera con restricciones combinadas;
- preguntas trampa con premisas falsas;
- casos adversariales y de seguridad.

8. Decisión clave: evaluación transversal de las siete dimensiones

Aunque cada caso tiene una **dimensión principal**, todas las respuestas se califican en las siete dimensiones.

La razón es que un sistema educativo real debe mantener simultáneamente múltiples propiedades. Por ejemplo, una respuesta a un caso diseñado para D7 debe seguir siendo factual, no alucinar y respetar la seguridad.

Por ello:

- 42 respuestas por perfil;
- 7 puntuaciones por respuesta;
- 294 juicios dimensionales por perfil;
- 882 puntuaciones por evaluador para los tres perfiles.

Consecuencia y limitación

Esta decisión permite una visión integral, pero puede producir **saturación** en dimensiones que un caso no tensiona directamente. La memoria reconoce esta limitación y propone como trabajo futuro emplear esquemas de aplicabilidad condicional o pesos dinámicos según el tipo de caso.

9. Perfiles conversacionales comparados

Se emplea **el mismo modelo base** y se modifican únicamente las directrices de sistema. Esto permite aislar, en la medida del diseño experimental, el efecto de las instrucciones de rol.

Perfil 1 — Asistente Base

Directriz general sin condicionamiento pedagógico específico:

“You are a helpful assistant”.

Funciona como línea de control del comportamiento por defecto del modelo Instruct.

Perfil 2 — Tutor Directo

Enfoque expositivo:

- respuesta clara;
- rigor conceptual;
- adaptación al estudiante;
- ejemplos;
- sin prohibición específica de entregar directamente soluciones completas.

Perfil 3 — Tutor Socrático

Enfoque de andamiaje:

- no entregar soluciones completas;
- diagnosticar errores;
- formular preguntas;
- proporcionar pistas graduadas;
- orientar el razonamiento del estudiante.

¿Por qué estos tres perfiles?

Para comparar:

1. una línea base sin directrices educativas específicas;
2. una estrategia pedagógica expositiva;
3. una estrategia pedagógica socrática.

Todo ello manteniendo constante modelo, batería y parámetros de inferencia.

10. Selección del modelo y entorno experimental

Modelo

Meta-Llama-3-8B-Instruct

Configuración utilizada:

- tag Ollama: llama3:8b;
- cuantización: Q4_0;
- digest: 365c0bd3c000;
- motor de inferencia: Ollama v0.1.32;
- ejecución mediante API REST local /api/chat.

¿Por qué este modelo?

La selección responde a criterios operativos y metodológicos:

- pesos disponibles para ejecución local;
- posibilidad de conservar un entorno auditable y trazable;
- tamaño de 8B compatible con los recursos disponibles;
- variante Instruct preparada para seguimiento de instrucciones y diálogo;
- posibilidad de ejecutar exactamente el mismo modelo bajo los tres perfiles.

No se afirma que sea el mejor modelo educativo ni que represente a todos los LLMs.

11. Decisiones sobre los parámetros de inferencia

Se fijaron los mismos parámetros para los tres perfiles:

- temperatura: $T = 0,20$;
- top-p: **0,90**;
- repeat penalty: **1,10**;
- seed: **42**;
- num_ctx: **2048**.

Razón

Los valores actúan como **variables de control**. No fueron optimizados para maximizar la puntuación de ninguno de los perfiles.

- $T = 0,20$ y top-p = 0,90: valores conservadores para reducir variabilidad manteniendo cierto margen de diversidad.
- repeat penalty = 1,10: penalización moderada de repeticiones.
- seed = 42: semilla arbitraria pero fija para favorecer comparabilidad.
- num_ctx = 2048: suficiente para la extensión de todos los casos y dentro de la capacidad del modelo.

Decisión: una ejecución por caso

Cada caso se ejecutó una sola vez con semilla fija.

Esto permite un experimento controlado y trazable, pero **no permite interpretar HR como una probabilidad universal de alucinación**. Las tasas representan los fallos observados en esa ejecución concreta.

La repetición con múltiples semillas se deja para trabajo futuro.

12. Proceso experimental completo

El flujo final es:

1. **Diseño de los 42 casos de prueba.**
2. **Configuración del perfil conversacional.**
3. **Ejecución real mediante Ollama.**
4. **Almacenamiento de la respuesta completa y metadatos en JSON.**
5. **Evaluación manual con rúbrica 0–3 en D1–D7.**
6. **Normalización y validación de las anotaciones.**
7. **Cálculo automático de métricas.**
8. **Cálculo de concordancia inter-evaluador.**
9. **Generación de tablas y gráficos.**
10. **Aplicación de la regla Safety-First e interpretación de resultados.**

Se obtuvieron:

- $42 \text{ casos} \times 3 \text{ perfiles} = 126 \text{ interacciones reales}$;
 - $126 \times 7 = 882 \text{ puntuaciones por evaluador}$.
-

13. Decisiones sobre la evaluación humana

Dos evaluadores y protocolo en dos fases

Las 126 respuestas fueron evaluadas mediante la misma rúbrica por dos evaluadores:

- **Evaluador 1 (E1):** autor del trabajo (evaluador en la Fase 1 independiente y participante en la revisión de Fase 2).
- **Evaluador 2 (E2):** segundo evaluador independiente con formación técnica en Informática (Fase 1).

¿Cómo se calculan las métricas oficiales y la concordancia?

Las métricas oficiales IQE, CFR y HR se calculan sobre el **Gold Standard humano consolidado en la Fase 2**. La concordancia inter-evaluador se calcula exclusivamente sobre las anotaciones independientes de E1 y E2 de la Fase 1.

- En la **Fase 1**, E1 y E2 realizaron la calificación a ciegas e independiente de las 126 interacciones (882 juicios pareados), sirviendo exclusivamente para medir la fiabilidad y consistencia del instrumento ($\kappa = 0,974$).
- En la **Fase 2**, tras una auditoría y calibración sistemática con adjudicaciones explícitas documentadas, se consolidó el **Gold Standard humano consolidado de Fase 2**, sobre el cual se calculan todas las métricas oficiales del trabajo (*IQE*, *CFR*, *HR*) y se evalúa el juez automático como referencia canónica final.

Decisión de cegamiento

Los evaluadores no accedieron:

- a las valoraciones del otro evaluador;
- a la etiqueta explícita del perfil de origen durante la calificación.

La etiqueta de perfil se restauró posteriormente en los datos estructurados para mantener la trazabilidad.

Limitación del cegamiento

El cegamiento no puede considerarse absoluto: el estilo de ciertas respuestas podía permitir inferir indirectamente qué configuración había producido la salida.

14. Decisión sobre Kappa de Cohen y Protocolo en Dos Fases

Se evaluó la concordancia inter-evaluador mediante un protocolo formal en dos fases:

1. **Fase 1 (Doble evaluación independiente a ciegas):**
 - $N_{\kappa} = 126 \text{ respuestas} \times 7 \text{ dimensiones} = 882 \text{ juicios pareados}$.
 - $P_o = 0,9955$ (878/882 acuerdos exactos, solo 4 discrepancias de 1 nivel).
 - $P_e = 0,8243$.
 - $\kappa_{\text{no-ponderado}} = 0,9742$ (*Acuerdo casi perfecto / Excelente* según Landis y Koch).
 - $\kappa_{\text{lineal}} = 0,9807$ y $\kappa_{\text{cuadrático}} = 0,9884$ (ponderación ordinal de Cohen).
2. **Fase 2 (Revisión, calibración y consolidación del Gold Standard):**
 - Tras la doble evaluación independiente, se realizó una exhaustiva auditoría y calibración técnica contrastando cada caso con las rúbricas formales y soluciones canónicas, consolidando un único conjunto canónico de referencia (*Gold Standard*) sobre el que se calculan las métricas oficiales (*IQE*, *CFR*, *HR*) y se evalúa el juez automático.

Interpretación metodológica

La interpretación correcta es **alta consistencia y reproducibilidad operativa de aplicación de la rúbrica en esta muestra**.

No significa que las puntuaciones sean necesariamente verdaderas desde el punto de vista disciplinar: dos evaluadores podrían coincidir en un mismo error disciplinar.

15. Métricas utilizadas

Media dimensional

Mide el comportamiento promedio en cada dimensión D1–D7 sobre las 42 respuestas de cada perfil.

CR — Tasa de cumplimiento

Proporción de respuestas con puntuación igual o superior a 2 en una dimensión.

CFR — Critical Failure Rate

Un caso se considera crítico cuando:

$$s_{i,1} = 0 \text{ o } s_{i,2} = 0 \text{ o } s_{i,5} = 0.$$

D1, D2 y D5 se consideran no negociables porque corresponden respectivamente a:

- corrección factual;
- control de alucinaciones;
- seguridad e integridad.

HR — Hallucination Rate

Se calcula específicamente sobre los casos de la subbatería de alucinaciones y cuenta aquellos en los que $D2 = 0$.

IQE — Índice de Calidad Educativa

Convierte las medias dimensionales en una medida sintética 0–100.

Pesos definidos a priori:

- D1: 0,25;
- D2: 0,20;
- D3: 0,15;
- D4: 0,15;
- D5: 0,10;
- D6: 0,10;
- D7: 0,05.

16. Decisión sobre los pesos del IQE

Los pesos **no proceden de una estimación empírica ni se presentan como universales**.

Son una parametrización de referencia definida a priori.

Criterio seguido

Se otorga mayor peso a:

1. factualidad;
2. control de alucinaciones;

porque una respuesta pedagógicamente atractiva pierde valor si transmite información falsa.

Claridad y feedback reciben un peso intermedio y aspectos como formato reciben menor peso.

¿Cómo se comprueba que el resultado no depende sólo de estos pesos?

Un análisis de sensibilidad con ponderación equiprobable ($w_d = 1/7 \approx 0,143$) produce valores de IQE de **83,56** para el Asistente Base, **88,55** para el Tutor Directo y **94,10** para el Tutor Socrático (a un decimal: **83,6 / 88,5 / 94,1**), manteniéndose la comparación relativa observada con la ponderación de diseño ($83,5 < 87,3 < 92,6$) y confirmando que el orden relativo no depende críticamente del vector de pesos elegido.

17. Decisión Safety-First

El IQE resume calidad, pero **no se utiliza como única regla de aceptación**.

Se define un criterio Safety-First:

Si existe algún fallo crítico en D1, D2 o D5, el perfil no puede considerarse apto para despliegue docente autónomo, independientemente de que su IQE sea elevado.

¿Por qué?

Porque un promedio puede compensar matemáticamente un fallo grave.

Ejemplo conceptual:

- un chatbot puede ser excelente en claridad, adaptación y formato;
- pero si inventa información o cede ante fraude académico;
- una media elevada no debería ocultar ese riesgo.

Esta separación entre **calidad global** y **riesgo crítico** constituye una de las ideas principales del trabajo.

18. Resultados experimentales

Perfil	IQE	CFR	HR	D1	D2	D3	D4	D5	D6	D7
Asistente Base	83,5	14,3 %	33,3 %	2,43	2,86	2,83	1,88	2,76	2,07	2,71
Tutor Di-	87,3	14,3 %	33,3 %	2,48	2,86	2,88	1,93	2,76	2,93	2,76
recto										
Tutor Socrático	92,6	11,9 %	16,7 %	2,45	2,88	2,93	2,81	2,93	2,95	2,81

Subbatería específica de feedback (Casos primarios de tensión)

Media D4 en FEED ($N = 6$):

- Base: **1,33** (vs. 1,88 transversal, $\Delta = +0,55$)
- Directo: **1,50** (vs. 1,93 transversal, $\Delta = +0,43$)
- Socrático: **1,67** (vs. 2,81 transversal, $\Delta = +1,14$)

El Socrático obtiene la mayor media de feedback formativo, si bien polariza su comportamiento entre andamiajes óptimos y fallos severos de diagnóstico conceptual.

19. Qué muestran realmente los resultados

19.1. El System Prompt modifica el comportamiento

El mismo modelo base produce comportamientos diferentes cuando se modifica la directriz de sistema.

El Tutor Socrático mejora especialmente en:

- D4 (Feedback Pedagógico);
- D5 (Robustez y Seguridad);
- D7 (Seguimiento de Instrucciones);
- calidad global IQE (92,6 vs. 83,5).

19.2. Una mejora global no implica menor riesgo

El Tutor Directo obtiene mayor IQE que la línea Base:

- Base: 83,5
- Directo: 87,3

pero mantiene una tasa de fallos críticos idéntica y elevada ($CFR = 14,3\%$, con 6 casos críticos de 42: FACT_006, FEED_002, ALUC_001, ALUC_005, SEC_002 y SEC_005).

Esto muestra, dentro de la batería evaluada, que una única métrica escalar agregada puede resultar insuficiente para auditar asistentes educativos.

19.3. El Socrático tampoco es “seguro” por defecto

Aunque obtiene $IQE = 92,6$ y la mayor D4, mantiene $CFR = 11,9 \%$ (5 casos críticos de 42).

Por ello tampoco supera Safety-First.

Conclusión experimental principal

Ninguno de los tres perfiles puede considerarse apto para un despliegue docente autónomo sin salvaguardas adicionales bajo el criterio definido en este trabajo.

20. Qué NO muestran los resultados del experimento

Es importante no sobreinterpretar los resultados.

El trabajo **no concluye de forma general** que:

- Llama 3 tenga una probabilidad universal de alucinación del 16,7 % o 33,3 %;
- el Tutor Socrático sea universalmente superior en todos los contextos;
- $D4 = 2,81$ implique que los estudiantes aprendan más;
- los pesos del IQE sean universales;
- los siete constructos sean completamente independientes;
- 42 casos sean suficientes para certificar un sistema educativo;
- los resultados se generalicen automáticamente a otros modelos;
- la metodología sustituya una evaluación pedagógica con estudiantes reales.

Lo que sí muestran los resultados es que **la metodología resulta viable y suficientemente sensible para identificar diferencias relevantes entre configuraciones en esta validación preliminar.**

21. Limitaciones asumidas deliberadamente

1. **Un único modelo:** Meta-Llama-3-8B-Instruct.
2. **42 casos:** volumen suficiente para una validación preliminar, pero no para un benchmark exhaustivo.
3. **Una ejecución por caso:** no se estudia variabilidad entre semillas.
4. **Seed fija = 42:** facilita comparabilidad, pero no caracteriza toda la distribución de comportamiento.
5. **Predominio del español con un modelo cuya documentación prioriza inglés.**
6. **Sólo texto y código:** se excluyen imágenes, diagramas y otros escenarios multimodales.
7. **D4 es una operacionalización del comportamiento pedagógico**, no una medición del aprendizaje real de estudiantes.
8. **Los casos son escenarios de testing**, no conversaciones longitudinales naturales de aula.
9. **Posible efecto techo**, especialmente en perfiles instruidos.
10. **Posible saturación transversal**, porque las siete dimensiones se califican en todos los casos.
11. **Dependencia parcial entre constructos**, especialmente D1 y D2.
12. **Posible sesgo del investigador**, ya que E1 es también el autor.
13. **Panel reducido de evaluadores**, sin especialistas independientes para cada dominio curricular.

14. **Cegamiento imperfecto**, porque el estilo lingüístico podría revelar indirectamente el perfil.
15. **No estacionariedad de modelos comerciales y ecosistemas de IA.**

22. Decisiones metodológicas: registro consolidado

Decisión	Elección realizada	Motivo	Consecuencia / límite
Tipo de evaluación	Caja negra sobre comportamiento conversacional	Evaluar el sistema desde la salida observable	No se estudian pesos internos
Modalidad	Texto y código	Delimitar el alcance	No se cubre multimodalidad
Nº de dimensiones	7	Integrar software, seguridad y pedagogía	Algunas dimensiones pueden correlacionar
Escala	0-3 sin punto medio	Forzar discriminación entre insuficiente/aceptable	No elimina todos los sesgos
Nivel 3 en D1	Correcto + suficientemente completo	Evitar premiar evasión o respuestas incompletas	Requiere juicio disciplinar
Nº de casos	42	Equilibrio entre cobertura y auditabilidad manual	Validación preliminar
Casos por dimensión principal	6	Simetría de cobertura	Muestra limitada
Evaluación transversal	D1-D7 para todas las respuestas	Exigir calidad integral	Puede generar saturación
Perfiles	Base, Directo y Socrático	Comparar control + dos enfoques pedagógicos	No cubre todas las estrategias posibles
Modelo	Meta-Llama-3-8B-Instruct	Local, auditable, 8B, Instruct	No representa a todos los LLM
Runtime	Ollama local	Control y trazabilidad	Dependencia del entorno local
Cuantización	Q4_0	Viabilizar ejecución con recursos disponibles	Puede diferir del modelo a precisión completa
Temperatura	0,20	Reducir variabilidad	No es un óptimo universal
top-p	0,90	Muestreo conservador con diversidad	No fue optimizado
repeat penalty	1,10	Penalización moderada de repetición	Elección operacional
seed	42	Comparabilidad	No estudia variabilidad estocástica
num_ctx	2048	Suficiente para todos los casos	No explota la ventana máxima
Nº de ejecuciones	1 por caso y perfil	Experimento controlado y manejable	HR no es probabilidad universal
Fiabilidad humana (Fase 1)	Doble evaluación independiente E1/E2	Evaluar consistencia y reproducibilidad del instrumento	Panel de 2 evaluadores
Segundo evaluador	E2 para consistencia	Estimar reproducibilidad de aplicación	Panel reducido
Cegamiento	Etiqueta explícita del perfil oculta	Reducir sesgo de expectativa	El estilo podía delatar perfil
Kappa	Cohen no ponderado	Medir acuerdo exacto	No aprovecha distancia ordinal
N de Kappa	882 pares	126 respuestas $\times$ 7 dimensiones	Acuerdo sobre esta muestra

Decisión	Elección realizada	Motivo	Consecuencia / límite
Pesos IQE	0,25/0,20/0,15/0,15/0,10/0,10/0,05/0,05	Optimizar factualidad y alucinaciones	Parametrización propia
Sensibilidad	Repetición con pesos iguales	Comprobar dependencia del vector de pesos	No sustituye validación externa
Dimensiones críticas	D1, D2 y D5	Factualidad, alucinaciones y seguridad no negociables	Regla conservadora
Safety-First	CFR > 0 impide despliegue autónomo	Evitar compensación de fallos graves por medias altas	No equivale a norma institucional
HR	D2 = 0 en subbatería de alucinaciones	Aislar fallos explícitos ante premisas falsas	Muestra de seis casos
Métricas principales	Gold Standard humano consolidado de Fase 2	Dataset canónico tras auditoría y calibración	Trazabilidad completa con Fase 1
Datos	Respuestas y anotaciones versionadas	Trazabilidad y réplica	La réplica puede variar por entorno
Código	Python modular	Automatizar análisis y visualización	Evaluación cualitativa sigue siendo humana
Regla de despliegue	Diagnóstico, no certificación	Proporcionar evidencia para una decisión	No sustituye validación institucional

23. Arquitectura del software

El proyecto separa responsabilidades:

- **src/utils/loader_prompts.py:** carga de casos.
- **src/evaluador/ejecutor_pruebas.py:** ejecución de inferencias vía Ollama.
- **src/analisis/metricas_tfg.py:** métricas matemáticas.
- **src/analisis/analizador_experimentos.py:** agregación global.
- **src/analisis/calcular_concordancia_evaluadores.py:** Kappa global y por dimensión.
- **src/analisis/importar_evaluaciones_humanas.py:** normalización de anotaciones.
- **src/analisis/validar_datos_evaluacion.py:** validación de integridad.
- **src/evaluador/evaluador_llm_judge.py:** motor independiente de evaluación automática LLM-as-a-Judge.
- **src/analisis/analizar_concordancia_llm_judge.py:** pipeline estadístico de concordancia Humano-IA.
- **src/visualizacion/generar_graficos.py:** generación de gráficos principales.
- **src/visualizacion/generar_graficos_llm_judge.py:** generación de gráficos vectoriales del juez automático.
- **tests unitarios:** comprobación de fórmulas, parser y condiciones de frontera.

En el experimento principal, la aplicación de la rúbrica continúa siendo humana. La extensión LLM-as-a-Judge estudia de forma separada su posible automatización parcial.

24. Extensión experimental: Evaluación automática mediante LLM-as-a-Judge

Motivación y cuello de botella humano

En el marco principal del TFG, la generación de respuestas, almacenamiento y cálculo de métricas están automatizados, pero la aplicación de la rúbrica D_1 - D_7 requiere evaluación manual. Para estudiar la escalabilidad de la metodología frente a baterías masivas de pruebas, se incorporó una extensión experimental basada en **LLM-as-a-Judge**.

Arquitectura y salvaguardas metodológicas

1. **Evaluación ciega respecto al perfil generador y a las evaluaciones humanas:** El juez recibe el prompt discente, ground truth, criterio de fallo crítico y la rúbrica completa 0–3, pero **no conoce el perfil** que generó la respuesta (Base, Directo o Socrático) para evitar sesgos pedagógicos preconcebidos.
2. **Aislamiento de datos:** El juez **nunca recibe las calificaciones de E1 ni E2**. Sus salidas se custodian en `data/evaluaciones/llm_judge/` (separando trazas raw y JSON normalizado), manteniendo intactos los datos humanos de referencia.
3. **Prompt congelado:** Se utiliza `judge_prompt_v1`, congelado antes del análisis para evitar optimizar el prompt contra el conjunto de validación.
4. **Modelo juez independiente:** Se establece como modelo de referencia **Qwen2.5-14B-Instruct** (configuración de baja variabilidad, $T = 0.0$, $\text{top-p}=0.9$, $\text{seed}=42$) para evitar autopreferencia con el evaluado **Meta-Llama-3-8B-Instruct**.

Pipeline de análisis de concordancia Humano–IA

- **Comparación principal (Juez vs. Gold Standard, $N_\kappa = 882$):** La evaluación canónica de fiabilidad del LLM Judge se realiza formalmente contra el **Gold Standard humano consolidado de Fase 2** ($\kappa = 0,186$, $\kappa_{\text{lineal}} = 0,280$, $\kappa_{\text{cuadrático}} = 0,368$). Las comparaciones frente a E_1 y E_2 se calculan como análisis diagnósticos complementarios de consistencia.
- **Análisis de granularidad:** Desglose de distribución de deltas ($|\Delta| \in \{0, 1, 2, 3\}$), matrices de confusión 4×4 y análisis de discrepancias direccionales frente al Gold Standard.
- **Control de fallos críticos (Safety-First):** Cálculo de sensibilidad, especificidad y tasa de falsos negativos en D_1 , D_2 y D_5 para verificar que el juez no apruebe respuestas con alucinaciones o vulneraciones de seguridad ética.

Propuesta futura: Sistema híbrido Humano-in-the-Loop

El juez automático no reemplaza la supervisión humana, sino que actúa como **filtro de triaje masivo de primer nivel**:

$$\text{LLM Judge (100\% pruebas)} \longrightarrow \begin{cases} \text{Aprobación directa,} & \text{si cumple todas las dimensiones con alta certidumbre} \\ \text{Auditoría Humana,} & \text{si detecta fallo crítico } (S_d = 0), \text{ baja confianza o discrepancias} \end{cases}$$

25. Aportaciones principales

Aportación metodológica

Un marco operativo que traduce un problema abierto de lenguaje natural a dimensiones y criterios observables.

Aportación de testing

Separar:

- calidad global;
- fallos críticos;
- alucinaciones.

Aportación pedagógica

No tratar un tutor educativo como un simple sistema de question answering: se evalúa si diagnostica, guía y adapta.

Aportación experimental

Una batería real aplicada a 126 interacciones de un modelo ejecutado localmente, complementada con un protocolo de evaluación automática mediante LLM-as-a-Judge.

Aportación software

Una implementación reproducible y versionada para repetir el análisis y extenderlo.

Aportación de datos

Casos, respuestas, anotaciones humanas y trazas experimentales disponibles para inspección y réplica.

26. Trabajo futuro derivado de las decisiones actuales

Las limitaciones del diseño conducen directamente a las siguientes extensiones:

- sistemas híbridos de triaje Humano-in-the-Loop;
 - ensambles de jueces automáticos y especialización de modelos por dimensión;
 - paneles multidisciplinares de evaluadores;
 - más modelos y materias;
 - múltiples semillas por caso;
 - casos adversariales más difíciles;
 - pesos o aplicabilidad condicional por dimensión;
 - Kappa ponderado;
 - evaluación multimodal;
 - testing metamórfico;
 - generación automática de variantes de prompts;
 - integración continua CI/CD;
 - evaluación de RAG y fidelidad de fuentes;
 - estudios con estudiantes reales para medir eficacia educativa.
-

26b. Extensión Experimental: Evaluación Automática (LLM-as-a-Judge)

¿Qué se ha realizado?

Se ha evaluado experimentalmente la viabilidad de automatizar la rúbrica analítica $D_1 \dots D_7$ utilizando un modelo evaluador independiente (Qwen2.5-14B-Instruct, Q4_K_M) en modo ciego sobre las 126 respuestas reales (882 juicios emparejados).

Resultados empíricos clave:

1. **Error numérico medio:** MAE = 0,498 puntos en escala 0–3, con un 63,04% de acuerdo exacto (556/882) y un 91,04% en tolerancia ± 1 nivel (803/882).
 2. **Concordancia diferenciada por dimensión:** Mayor convergencia en Seguridad (D_5 , $\kappa = 0,421$, 90,48% exacto) y Alucinaciones (D_2 , $\kappa = 0,327$, 88,89% exacto), frente a concordancia leve en dimensiones pedagógicas y estilísticas (D_3 , D_4 , D_6). Al incorporar distancia ordinal, el coeficiente asciende a $\kappa_{\text{lineal}} = 0,280$ y $\kappa_{\text{cuadrático}} = 0,368$.
 3. **Sensibilidad Safety-First insuficiente:** Aunque la exactitud global alcanzó el 88,10% (111/126), la sensibilidad para detectar respuestas con fallos críticos fue del 47,06% (detectando 8 de las 17 respuestas críticas, FNR = 52,94%). Detectó el 100,0% de los fallos de seguridad (D_5 , 5/5), el 60,0% de alucinaciones (D_2 , 3/5) y el 27,27% de errores factuales (D_1 , 3/11).
 4. **Conclusión metodológica:** La aplicación automatizada de la rúbrica es técnicamente viable, pero su concordancia no ponderada leve ($\kappa = 0,186$ global) y su baja sensibilidad ante fallos críticos impiden su uso como evaluador autónomo, restringiéndolo a soporte de triaje bajo supervisión humana (*Human-in-the-Loop*). Viabilidad técnica $\neq$ fiabilidad evaluativa.
-

27. Cómo explicar el TFG en una defensa

En 20 segundos

El trabajo aborda un problema de testing: un chatbot basado en LLM no tiene una única salida correcta y, en educación, una respuesta puede ser fluida pero falsa, insegura o pedagógicamente inadecuada. Por eso diseño una metodología multidimensional con rúbricas, casos de prueba, métricas de calidad y un criterio Safety-First, la valido sobre tres configuraciones del mismo Llama 3, y formulo una extensión experimental para automatizar la rúbrica mediante LLM-as-a-Judge.

En una frase

El TFG propone una forma sistemática de comprobar no sólo si un chatbot educativo responde bien, sino si responde de forma factual, segura y pedagógicamente adecuada, evitando que una nota media alta oculte fallos críticos.

Hallazgo que conviene recordar

El Tutor Directo mejora el IQE respecto al Asistente Base, pero mantiene la misma tasa de fallos críticos (14,3 %); por tanto, una mejora de la calidad global no implica necesariamente una reducción del riesgo crítico.

28. Mensaje final

El proyecto no pretende declarar que un determinado LLM es “bueno” o “malo” para educación de forma universal.

Su aportación es proporcionar una **metodología de ingeniería del software para producir evidencia estructurada sobre su comportamiento**, haciendo visibles de forma separada:

- calidad conceptual;
- calidad pedagógica;
- cumplimiento;
- seguridad;
- fallos críticos.

La idea final del TFG es que **la adopción de IA generativa en educación no debería decidirse únicamente por lo convincente que parezca una respuesta ni por una puntuación global**, sino mediante pruebas sistemáticas que permitan identificar explícitamente qué funciona, qué falla y qué riesgos siguen siendo inaceptables.